

Rozpoznawanie akcji na danych szkieletowych w oparciu o prostą ST-GCN

1. Cel projektu

Celem projektu było opracowanie i eksperymentalna walidacja metod rozpoznawania akcji na podstawie danych szkieletowych. Projekt realizowany był w dwóch etapach:

- **CV_Proj1:** Ekstrakcja danych szkieletowych przy użyciu MediaPipe oraz wstępne przetwarzanie danych na potrzeby klasyfikacji.
- **CV_Proj2:** Implementacja i testowanie modelu ST-GCN do klasyfikacji akcji na podstawie przetworzonych danych.

2. Skład grupy

- Tomasz Bochnak, Jakub Łubkowski, Marcin Miłucha, Szymon Słota, Paweł Steczkiewicz

3. Przebieg realizacji projektu

3.1. CV_Proj1: Ekstrakcja i wstępne przetwarzanie danych szkieletowych

W pierwszym etapie projektu zajęliśmy się przygotowaniem danych wejściowych dla modelu klasyfikacyjnego. W tym celu:

- Stworzono skrypt do wczytywania sekwencji obrazów z plików wideo oraz pojedynczych plików graficznych.
- Przetestowano różne modele MediaPipe do ekstrakcji danych szkieletowych i oceniono ich skuteczność.
- Zaimplementowano zapis wykrytych punktów szkieletowych do plików **JSON** oraz **CSV**.
- Stworzono metodę augmentacji danych szkieletowych, obejmującą losowe przesunięcia i skalowanie punktów kluczowych.
- Przygotowano skrypt do wizualizacji danych przed i po augmentacji w dwóch oknach.

Ze względu na nienajlepsze wyniki ekstrakcji punktów kluczowych z MediaPipe, porzuciliśmy tę metodę na rzecz innego podejścia w drugim etapie projektu.

3.2. CV_Proj2: Implementacja klasyfikacji za pomocą ST-GCN

Drugi etap projektu obejmował implementację modelu ST-GCN, który został przystosowany do analizy danych szkieletowych:

- W CV_Proj2 wykorzystano inną klasę z MediaPipe do generowania key pointów, co pozwoliło uzyskać lepsze rezultaty.
- Zamiast przetwarzania pojedynczych obrazów, zaimplementowano rozbijanie plików wideo na klatki, a następnie przypisywanie każdej klatce odpowiedniej klasy ręcznie.
- Przetworzono dane do postaci odpowiedniej dla modeli grafowych.

- Zaimplementowano model ST-GCN w oparciu o bibliotekę torch-geometric.
- Stworzono skrypt do uczenia modelu na przetworzonych danych oraz do testowania jego skuteczności.
- Przeprowadzono trening oraz testy modelu, uzyskując dokładność 77,41% na zbiorze testowym.

4. Podsumowanie

W ramach projektu opracowano pipeline przetwarzania danych szkieletowych oraz ich klasyfikacji za pomocą modelu ST-GCN. Zastosowanie alternatywnej biblioteki do generowania punktów kluczowych oraz podejście oparte na analizie klatek z wideo pozwoliły uzyskać całkiem niezłe wyniki.